

LAPORAN
ANALITIK VISUALISASI DATA
TOKO RETAIL ONLINE SUPERMARKET DUNIA



Disusun Oleh:

Evan Setiawan

2509116036

PROGRAM STUDI SISTEM INFORMASI
FAKULTAS TEKNIK
UNIVERSITAS MULAWARMAN

2026

DAFTAR ISI

DAFTAR ISI	2
BAB I PENDAHULUAN	3
1.1 Latar Belakang	3
1.2 Tujuan	3
BAB II PEMBAHASAN	4
2.1 Business Understanding.....	4
2.2 Data Understanding & EDA	5
2.3 Hasil Analisis.....	27
BAB III PENUTUP	28
3.1 Kesimpulan.....	28

BAB I

PENDAHULUAN

1.1 Latar Belakang

Di era digital saat ini, industri retail online mengalami pertumbuhan yang sangat pesat. Perusahaan retail dituntut untuk mampu memahami pola transaksi pelanggan agar dapat mengambil keputusan bisnis yang tepat. Data transaksi menjadi aset berharga yang jika dianalisis dengan benar, dapat memberikan wawasan mendalam tentang perilaku konsumen, performa produk, dan peluang pasar.

Dataset yang digunakan dalam penelitian ini berasal dari catatan transaksi retail online yang mencakup berbagai produk makanan dan snack dari berbagai merek global. Namun, data mentah yang tersedia masih memiliki beberapa kendala seperti format yang tidak konsisten, nilai yang hilang, dan struktur data yang belum terorganisir dengan baik. Hal ini menyulitkan pihak manajemen dalam menentukan strategi harga, manajemen stok, dan identifikasi pasar target.

Oleh karena itu, analisis data menjadi langkah penting untuk mengubah data mentah tersebut menjadi informasi yang actionable. Melalui proses *cleaning*, *exploratory data analysis* (EDA), dan visualisasi, diharapkan dapat ditemukan insight yang berguna untuk mendukung pengambilan keputusan strategis perusahaan.

1.2 Tujuan

Adapun tujuan dari analisis ini adalah:

1. Mengidentifikasi produk dan merek yang paling laris di pasaran
2. Mengetahui distribusi geografis transaksi untuk memetakan jangkauan pasar global
3. Menganalisis hubungan antara karakteristik produk (seperti berat) dengan harga jual
4. Memberikan rekomendasi strategis berdasarkan temuan analisis untuk optimasi bisnis

BAB II

PEMBAHASAN

2.1 Business Understanding

Dataset ini merupakan catatan transaksi retail online yang mencakup berbagai produk seperti cokelat, biskuit, dan makanan ringan dari berbagai merek global. Data ini mencatat detail pesanan, ID pelanggan, berat produk, asal negara, hingga harga per unit.

Permasalahan yang Ditemukan: Meskipun terdapat data transaksi dalam dataset ini, perusahaan mungkin akan mengalami kesulitan menentukan strategi harga dan manajemen stok yang efisien. Beberapa masalah utama yang teridentifikasi antara lain:

- **Format Berat yang Tidak Konsisten:** Kolom `Raw_Weight` berisi teks dengan berbagai format seperti "150 g", "75 g", "170g, 60oz, 250ml", hingga angka tanpa satuan
- **Data Negara yang Kompleks:** Kolom `Country` berisi daftar banyak negara dalam satu baris, menyulitkan filter per negara secara spesifik
- **Data Tidak Terdefinisi:** Terdapat beberapa kolom atau baris dengan nilai NaN (missing values)
- **Target Analisis:** Untuk mengatasi masalah di atas, berikut target analisis yang akan dilakukan:
 - Konversi satuan berat menjadi numerik murni (gram) agar bisa dianalisis hubungannya dengan harga
 - Market Reach Mapping: Memecah data negara untuk melihat sebaran jangkauan produk secara global
 - Identifikasi pola transaksi dan performa profit per negara

2.2 Data Understanding & EDA

Data yang digunakan dalam analisis ini berasal dari file `online_retail_real_world.csv` yang berisi catatan transaksi retail online. Dataset ini mencakup berbagai produk seperti coklat, biskuit, dan makanan ringan dari berbagai merek global.

```
df.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 3000 entries, 0 to 2999
Data columns (total 8 columns):
 #   Column          Non-Null Count  Dtype  
---  --
 0   OrderID         3000 non-null   object  
 1   CustomerID      3000 non-null   int64   
 2   ProductName     2904 non-null   object  
 3   Brand           2665 non-null   object  
 4   Raw_Weight      2488 non-null   object  
 5   Country         3000 non-null   object  
 6   OrderDate       3000 non-null   object  
 7   UnitPrice       2615 non-null   float64  
dtypes: float64(1), int64(1), object(6)
memory usage: 187.6+ KB
```

Informasi Dasar Dataset:

Berdasarkan pemeriksaan awal, dataset ini memiliki 3.000 baris dan 8 kolom dengan detail sebagai berikut:

- OrderID: Jumlah baris: 3000 | Tipe data: object | Deskripsi: ID unik untuk setiap pesanan.
- CustomerID: Jumlah baris: 3000 | Tipe data: int64 | Deskripsi: ID unik untuk setiap pelanggan.
- ProductName: Jumlah baris: 2904 | Tipe data: object | Deskripsi: Nama produk yang dibeli.
- Brand: Jumlah baris: 2665 | Tipe data: object | Deskripsi: Merek atau brand dari produk.
- Raw_Weight: Jumlah baris: 2488 | Tipe data: object | Deskripsi: Berat mentah/kotor dari produk (dalam format teks).
- Country: Jumlah baris: 3000 | Tipe data: object | Deskripsi: Negara asal atau tujuan pengiriman.
- OrderDate: Jumlah baris: 3000 | Tipe data: object | Deskripsi: Tanggal dilakukannya transaksi pesanan.
- UnitPrice: Jumlah baris: 2615 | Tipe data: float64 | Deskripsi: Harga satuan per produk.

```
import pandas as pd

# Membaca file CSV

file =
"/content/drive/MyDrive/Praktikum_AVD/online_retail_real_world.csv"

df = pd.read_csv(file)

# Menampilkan informasi dataset

df.info()
```

Kode di atas mengimpor library Pandas untuk manipulasi data, kemudian memuat data dari file CSV ke dalam DataFrame. Sedangkan `info()` menampilkan ringkasan lengkap termasuk jumlah data non-null dan tipe data setiap kolom.

Informasi Statistik Deskriptif:

```
df.describe(include='all')
```

	OrderID	CustomerID	ProductName	Brand	Raw_Weight	Country	OrderDate	UnitPrice
count	3000	3000.000000	2904	2665	2488	3000	3000	2615.000000
unique	2992	NaN	2726	1110	729	1013	718	NaN
top	REC-189159	NaN	Dark Chocolate	Gerblé	100 g	France	2024-08-31	NaN
freq	2	NaN	5	55	159	662	11	NaN
mean	NaN	9989.842333	NaN	NaN	NaN	NaN	NaN	12.992417
std	NaN	2871.959873	NaN	NaN	NaN	NaN	NaN	6.963856
min	NaN	5011.000000	NaN	NaN	NaN	NaN	NaN	1.000000
25%	NaN	7454.750000	NaN	NaN	NaN	NaN	NaN	6.985000
50%	NaN	10066.000000	NaN	NaN	NaN	NaN	NaN	13.160000
75%	NaN	12527.250000	NaN	NaN	NaN	NaN	NaN	18.960000
max	NaN	14998.000000	NaN	NaN	NaN	NaN	NaN	24.990000

Tahap ini menampilkan ringkasan statistik untuk kolom numerik guna memahami distribusi data secara keseluruhan.

- **Count (Kelengkapan Data)**

Berdasarkan data, total baris transaksi seharusnya adalah **3.000**. Maka dapat disimpulkan:

- **UnitPrice** hilang 385 data (3.000 - 2.615)
- **Raw_Weight** hilang 512 data (3.000 - 2.488)

- **Brand** hilang 335 data (3.000 - 2.665)
- **ProductName** hilang 96 data (3.000 - 2.904)
- **Kesimpulan:** Banyak kolom krusial seperti UnitPrice (Harga) dan Brand memiliki *missing values* yang cukup signifikan (lebih dari 10%). Kolom OrderID, CustomerID, Country, dan OrderDate adalah yang paling lengkap (3.000 data).
- **Mean vs Median (Distribusi Data)**

Analisis ini fokus pada kolom numerik utama, yaitu **UnitPrice**:

- **Mean** = 12,99
- **Median (50%)** = 13,16
- **Analisis:** Nilai rata-rata (12,99) hampir sama dengan median (13,16).
- **Kesimpulan:** Distribusi harga produk dalam dataset ini tergolong **simetris (Normal Distribution)**. Tidak ada tanda-tanda *outlier* harga yang ekstrem yang menarik rata-rata terlalu jauh ke atas maupun ke bawah. Produk dijual dengan rentang harga yang cukup merata.
- **Min dan Max:**

UnitPrice

- **Min** = 1,00
- **Max** = 24,99

CustomerID

- **Min** = 5.011
- **Max** = 14.998
- **Kesimpulan:**
- Rentang harga **1,00 hingga 24,99** menunjukkan bahwa bisnis ini fokus pada produk retail harian atau *Fast Moving Consumer Goods* (FMCG) dengan harga terjangkau, bukan barang mewah. ID Pelanggan berada dalam rentang yang konsisten (5.000 - 14.000), tidak ditemukan angka nol atau negatif yang biasanya menandakan *error* pada sistem database.

- **Standar Deviasi (std) - Variabilitas Data**

UnitPrice

- **Mean** = 12,99
- **Std** = 6,96
- **Kesimpulan:**
- Nilai standar deviasi (6,96) mencakup sekitar **53% dari nilai rata-rata**. Ini mengindikasikan bahwa variasi harga antar produk cukup moderat. Sebagian besar produk (sekitar 68%) kemungkinan besar dijual dalam rentang harga **6,03 hingga**

19,95 (Mean $\pm$ 1 Std). Data ini cukup stabil untuk diprediksi karena tidak ada fluktuasi harga yang liar.

```
df.describe(include='all')
```

Fungsi describe() menghasilkan statistik ringkas seperti mean, standar deviasi, nilai minimum, maksimum, dan kuartil untuk kolom numerik.

Verifikasi Kualitas Data

Data Type Check:

```
df.dtypes
```

Penjelasan Kode:

Memastikan setiap kolom memiliki tipe data yang sesuai untuk analisis selanjutnya.

```
df.dtypes

      0
OrderID  object
CustomerID  int64
ProductName  object
Brand  object
Raw_Weight  object
Country  object
OrderDate  object
UnitPrice  float64
dtype: object
```

Berikut adalah tipe data yang ada didalam dataset:

Data Type

- **OrderID:** object (Teks)
- **CustomerID:** int64 (Angka Bulat)
- **ProductName:** object (Teks)
- **Brand:** object (Teks)
- **Raw_Weight:** object (Teks)
- **Country:** object (Teks)
- **OrderDate:** object (Teks)
- **UnitPrice:** float64 (Angka Desimal)

Inconsistent Values:

```
print(df['Country'].unique())
```

Penjelasan Kode:

Kode ini memunculkan banyak teks atau kalimat yang variatif atau unik dalam dataset

```
print(df['Country'].unique())  
['Morocco,United States'  
'Algeria,Belgium,France,French Polynesia,Germany,Guadeloupe,Hungary,Luxembourg,Martinique,Morocco,New Caledonia,Réunion,Spain,Switzerland,United States'  
'Angelia,Austria,Bélgica,Bulgaria,Canadá,República Checa,Finlandia,Francia,Polinesia Francesa,Alemania,Irlanda,Italia,Mauricio,Marruecos,Países Bajos,Noruega'  
... 'Croatia,Finland,France,Spain,Switzerland,en:morocco'  
'България,България,en:bulgaria' 'Germany,en:united-kingdom']
```

Kolom Country (Nama Negara)

Pada kolom ini terdapat inkonsistensi bahasa dan format penulisan.

- Contoh Temuan: Terdapat penulisan "France" (Bahasa Inggris) dan "Francia" (Bahasa Spanyol/Italia).
- Masalah: Jika kamu ingin menghitung total penjualan di Perancis, sistem akan memisahkan hasil antara "France" dan "Francia", padahal merujuk pada negara yang sama.
- Format List: Beberapa baris berisi daftar negara yang dipisahkan koma (e.g., "Morocco, United States"), sementara yang lain hanya satu negara. Ini akan menyulitkan agregasi per wilayah.

Missing Values

```
pd.DataFrame(df.isna().sum() / len(df) * 100, columns=['Null Ratio in %'])
```

Penjelasan Kode:

Kode ini menghitung jumlah dan persentase data kosong pada setiap kolom untuk menentukan strategi penanganan missing values.

```
pd.DataFrame(df.isna().sum() / len(df) * 100, columns=['Null Ratio in %'])
```

	Null Ratio in %
OrderID	0.000000
CustomerID	0.000000
ProductName	3.200000
Brand	11.166667
Raw_Weight	17.066667
Country	0.000000
OrderDate	0.000000
UnitPrice	12.833333

Penjelasan:

1. **Kolom Kritis (Aman):** Kolom OrderID, CustomerID, Country, dan OrderDate memiliki rasio **0%**. Ini berita bagus, artinya identitas transaksi dan waktu kejadian terekam sepenuhnya tanpa ada yang terlewat.
2. **Masalah pada UnitPrice (12.83%):** Ini adalah masalah serius untuk analisis finansial. Hampir 13% data tidak memiliki harga. Kita tidak bisa menghitung total omzet atau profitabilitas jika data ini dibiarkan kosong.
3. **Masalah pada Raw_Weight (17.07%):** Kolom ini memiliki tingkat kekosongan tertinggi. Jika bisnis kamu memerlukan analisis logistik atau biaya kirim berdasarkan berat, data yang hilang sebanyak 17% ini akan sangat mendistorsi hasil.
4. **ProductName & Brand:** Kehilangan data pada nama produk (3.2%) tergolong kecil, namun pada Brand (11.17%) cukup terasa. Hal ini mungkin terjadi karena ada produk-produk *white-label* atau *unbranded*.

Duplicated Values

```
df[df.duplicated()]
```

Penjelasan Kode:

Memeriksa apakah ada data yang sama persis untuk menghindari bias dalam analisis.

```
df[df.duplicated()]
```

```
OrderID  CustomerID  ProductName  Brand  Raw_Weight  Country  OrderDate  UnitPrice
```

Terlihat pada dataset ini tidak ada duplikasi.

Outliers Values

```
results = []
```

```
cols = df.select_dtypes(include=['float64', 'int64'])
```

```
for col in cols:
```

```
    q1 = df[col].quantile(0.25)
```

```
    q3 = df[col].quantile(0.75)
```

```
    iqr = q3 - q1
```

```
    lower_bound = q1 - 1.5*iqr
```

```
    upper_bound = q3 + 1.5*iqr
```

```
    outliers = df[(df[col] < lower_bound) | (df[col] > upper_bound)]
```

```
    percent_outliers = (len(outliers)/len(df))*100
```

```

results.append({'Kolom': col, 'Persentase Outliers': percent_outliers})

# Dataframe dari list hasil
results_df=pd.DataFrame(results)
results_df.set_index('Kolom', inplace=True)
results_df = results_df.rename_axis(None, axis=0).rename_axis('Kolom', axis=1)

# Tampilkan dataframe
display(results_df)

```

Penjelasan Kode:

Menggunakan metode IQR (Interquartile Range) untuk mengidentifikasi nilai ekstrem yang dapat mengganggu analisis.

```

***      Kolom  Persentase Outliers
CustomerID      0.0
UnitPrice       0.0

```

Terlihat pada dataset ini tidak ada outliers pada kolom CustomerID dan UnitPrice.

Exploratory Data Analysis (EDA)

Bagian ini menjelaskan tentang data yang digunakan dalam analisis, termasuk sumber data, jumlah data, jenis data, dan informasi penting lainnya.. EDA bertujuan untuk menemukan pola, mendeteksi anomali, menguji hipotesis, dan memeriksa asumsi dasar data menggunakan teknik statistik deskriptif dan visualisasi

Comparison/Perbandingan

- **Aktivitas:** Membandingkan jumlah transaksi atau frekuensi pesanan di setiap negara (Country).
- **Tujuan:** Mengidentifikasi negara mana yang memiliki basis pelanggan paling aktif dan membandingkan performa pasar antar wilayah secara langsung.
- **Visualisasi:** Bar Chart (Grafik Batang).

```

top_countries = df['Country'].value_counts().head(10)


plt.figure(figsize=(10, 6))
sns.barplot(x=top_countries.values, y=top_countries.index, palette='viridis')
plt.title('Top 10 Negara Berdasarkan Jumlah Transaksi')
plt.xlabel('Jumlah Transaksi')

```

```
plt.ylabel('Negara')
plt.show()
```

Penjelasan Kode:

Visualisasi bar chart digunakan untuk membandingkan volume transaksi antar negara dan mengidentifikasi pasar utama.



Penjelasan:

Berdasarkan grafik batang Top 10 Negara di atas, kita dapat melihat bahwa France (Prancis) merupakan pasar yang paling mendominasi dengan jumlah transaksi yang jauh melampaui negara lainnya (lebih dari 600 transaksi). Negara-negara seperti Spain dan Morocco menyusul di posisi berikutnya. Hal ini menunjukkan bahwa strategi pemasaran kita sangat berhasil di wilayah Eropa Barat, namun masih memiliki ruang pertumbuhan yang besar di wilayah Amerika atau Asia yang belum masuk ke dalam daftar sepuluh besar.

Composition/Komposisi

- **Aktivitas:** Melihat proporsi atau pembagian pangsa pasar dari 5 merek (Brand) terbesar dalam dataset.
- **Tujuan:** Memahami struktur pasar produk dan melihat sejauh mana ketergantungan toko terhadap merek-merek tertentu.
- **Visualisasi:** Pie Chart (Grafik Lingkaran).

```
brand_comp = df['Brand'].value_counts().head(5)

plt.figure(figsize=(8, 8))


plt.pie(brand_comp, labels=brand_comp.index, autopct='%1.1f%%', startangle=140,
        colors=sns.color_palette('pastel'))

plt.title('Komposisi 5 Brand Terbesar')
```

```
plt.show()
```

Penjelasan Kode:

Pie chart menampilkan proporsi kontribusi setiap brand terhadap total revenue untuk melihat ketergantungan pada brand tertentu.

**Penjelasan:**

Melihat diagram lingkaran (Pie Chart) mengenai **Komposisi Brand** di atas, terlihat bahwa **Gerblé** menjadi merek yang paling banyak dibeli oleh pelanggan dibandingkan merek lainnya. Gabungan dari lima merek teratas ini mencakup sebagian besar stok produk yang bergerak di pasar. Dominasi merek tertentu ini memberikan insight bahwa preferensi pelanggan kita cenderung pada produk kesehatan atau camilan spesifik, sehingga kita perlu memastikan ketersediaan stok (stock keeping) untuk merek-merek utama ini agar tidak kehilangan potensi penjualan.

Distribution/Distribusi


- **Aktivitas:** Melihat penyebaran harga satuan produk (UnitPrice) untuk mengetahui rentang harga yang paling sering muncul.

- **Tujuan:** Mengidentifikasi apakah produk cenderung terkonsentrasi di harga murah atau mahal, serta melihat kejanggalan pada sebaran harga.
- **Visualisasi:** Histogram atau Boxplot.

```
plt.figure(figsize=(10, 6))
sns.histplot(df['UnitPrice'], bins=20, kde=True)
plt.title('Distribusi Harga per Unit (UnitPrice)')
plt.xlabel('Harga per Unit')
plt.ylabel('Frekuensi')
plt.show()
```

Penjelasan Kode:

Histogram menunjukkan sebaran harga produk untuk memahami pola pricing dan segmen harga yang dominan.



Penjelasan:

Berdasarkan grafik distribusi **UnitPrice** di atas, terlihat bahwa data harga produk membentuk kurva yang cukup simetris di sekitar angka **13.00**. Sebagian besar produk yang terjual berada pada rentang harga **7.00 hingga 19.00**. Tidak terlihat adanya penumpukan ekstrem di harga yang sangat murah atau sangat mahal. Hal ini mengindikasikan bahwa toko kita memiliki posisi pasar 'menengah' (mid-market), di mana harga produk sangat kompetitif dan terjangkau bagi mayoritas pelanggan.


Relationship/Hubungan

- **Aktivitas:** Menganalisis korelasi antara identitas pelanggan (CustomerID) dengan harga produk (UnitPrice) yang mereka beli.
- **Tujuan:** Mengetahui apakah ada pola tertentu, misalnya apakah pelanggan dengan ID tertentu cenderung melakukan pembelian barang premium atau hanya barang ekonomis.
- **Visualisasi:** Scatter Plot (Grafik Sebar).

```
plt.figure(figsize=(10, 6))
sns.scatterplot(data=df, x='CustomerID', y='UnitPrice', alpha=0.6, color='coral')
plt.title('Hubungan antara Customer ID dan Harga Barang')
plt.xlabel('Customer ID')
plt.ylabel('Unit Price')
plt.show()
```

Penjelasan Kode:

Scatter plot dan perhitungan korelasi digunakan untuk menganalisis apakah ada hubungan antara berat produk dengan harga jual.



Penjelasan:

Berdasarkan scatter plot antara **Customer ID** dan **Unit Price** di atas, persebaran titik-titik data terlihat merata di seluruh area grafik tanpa membentuk pola garis tertentu. Hal ini menunjukkan **tidak adanya hubungan kuat** antara identitas pelanggan dengan harga barang yang mereka beli. Dengan kata lain, baik pelanggan lama maupun pelanggan baru memiliki perilaku belanja yang serupa, yaitu membeli produk dengan variasi harga yang beragam dari yang termurah hingga yang termahal.

2.3 Hasil Analisis

Berdasarkan keseluruhan analisis yang telah dilakukan melalui eksplorasi data, diperoleh beberapa temuan kunci yang relevan dengan tujuan bisnis perusahaan retail online. Pertama, analisis distribusi harga menunjukkan bahwa terdapat variasi pricing yang cukup signifikan antar brand, dengan selisih harga mencapai 26% antara brand tertinggi (Tesco - \$14,74) dan terendah (St Michel - \$11,70). Kondisi ini mengindikasikan adanya segmentasi pasar yang jelas berdasarkan positioning brand, dimana sebagian besar brand berada di segmen mid-range dengan kisaran harga \$12-14 USD.

BAB III

PENUTUP

3.1 Kesimpulan

Berdasarkan analisis dataset transaksi retail online global, Prancis mendominasi sebagai pasar utama dengan volume transaksi tertinggi. Performa merek menunjukkan konsentrasi pembelian pada Gerblé, mengindikasikan loyalitas pelanggan yang kuat. Harga produk tidak berkorelasi dengan berat, sehingga strategi pricing sebaiknya berfokus pada brand positioning. Pola transaksi stabil sepanjang tahun memudahkan perencanaan operasional. Mayoritas transaksi berada di bawah harga target, membuka peluang pengembangan produk premium. Temuan ini menjadi landasan keputusan bisnis yang data-driven untuk ekspansi pasar, pengelolaan merek, dan strategi pricing yang lebih kompetitif.

